



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

پیشنهاد پروژه تحصیلات تکمیلی

(رساله کارشناسی ارشد و دکترا)

شماره:

تاریخ:

فرم پروژه تحصیلات تکمیلی 1

1- مشخصات دانشجو

شماره دانشجویی: ۴۰۲۱۳۱۰۵۳
دانشکده: مهندسی کامپیوتر
مقطع: کارشناسی ارشد
تلفن: ۰۹۲۲۹۷۱۱۰۵۴

نام و نام خانوادگی: پویا مزجی
رشته تحصیلی: مهندسی کامپیوتر - گرایش نرم افزار
آدرس: تهران-جنت آباد مرکزی-مخبری-پ ۳۸

2- مشخصات استاد راهنما

سمت، مرتبه علمی و محل خدمت: عضو هیئت علمی - استادیار
تلفن:

نام و نام خانوادگی: دکتر امیر کلباسی
آدرس: تهران، دانشگاه صنعتی امیرکبیر، دانشکده مهندسی کامپیوتر

3- مشخصات استاد مشاور

سمت، مرتبه علمی:
تلفن:

نام و نام خانوادگی:

4- عنوان پایان نامه یا رساله

فارسی: بهبود محیط اجرای تابعها جهت کاهش تاخیر شروع سرد گردش کار در معماری تابع به عنوان خدمت
انگلیسی: Improving function runtime environment in FaaS to reduce workflow cold start

۶

تعداد واحد

توسعه ای

بنیادی

کاربردی

نوع پروژه:

۵- خلاصه پایان نامه: (مسئله فرضیات، هدف از اجراء، توجیه ضرورت انجام طرح)

معماری تابع به عنوان خدمت^۱، مدل ساده تر و راهکار آسان تری را برای محاسبات ابری^۲ ارائه می دهد. در این روش توسعه دهندگان با اطمینان خاطر از مسائل زیرساختی و مدیریتی همانند مدیریت منابع، مقیاس پذیری و در دسترس بودن سامانه که همگی برعهده ارائه دهنده ابر است، تمرکز خود را صرفاً بر روی توسعه نرم افزار می گذارند. این رویکرد باعث تسریع در تحویل نرم افزار و چابکی در توسعه محصول می شود. امروزه رایانش ابری با ظهور محاسبات بدون کارساز دچار تحول شده است و موجی از نوآوری را برانگیخته است. ویژگی برتر این معماری در مقایسه با انواع دیگر معماری ها در ابر، مناسب بودن آن برای نرم افزارهای رویداد محور است که در آن تابعها توسط رویدادها یا پیامها فراخوانی می شوند و پس از پردازش درخواست غیرفعال^۳ می شوند. از آنجایی که هزینه منابع تخصیص داده شده به خدمت گیرنده صرفاً هزینه زمان فعالیت تابعها می باشد، ارائه دهندگان ابر نیز در صورت عدم وجود پردازش، منابع خود را از مدار فعالیت خارج^۴ می کنند.

مفهوم محاسبات بدون کارساز، با معماری تابع به عنوان خدمت نمود پیدا می کند. در این معماری، توسعه دهندگان برای توسعه یک سامانه پیچیده، آن را به واحدهای کوچکتر تقسیم می کنند و یک گردش کار^۵ را تشکیل می دهند. یک گردش کار دنباله ای از فراخوانی های تابعهای مختلف برای ارائه یک خدمت به کاربر است. این رویکرد به حفظ سادگی و سرعت در توسعه سیستم های پیچیده کمک می کند. با وجود این، معماری تابع به عنوان خدمت بدون محدودیت نبوده و تاخیر شروع سرد^۶ یکی از مهم ترین محدودیت ها است [۱]. این مسئله به تاخیر ایجاد شده در شروع و راه اندازی اولیه یک تابع برای اولین بار (یا پس از یک دوره عدم فعالیت) اشاره می کند. مسئله ذکر شده می تواند بسته به نوع تابع و حجم کد آن، تاخیری از چند دهم ثانیه تا چندین ثانیه را به کاربران تابعها تحمیل کند. این تاخیر عملکرد و پاسخگویی برنامه های بدون کارساز، مخصوصاً سناریوهایی که زمان پاسخگویی با تاخیر پایین بسیار اهمیت دارد، تاثیر منفی می گذارد. تاخیر شروع سرد در مقیاس پذیری نیز اثر می گذارد [۲]. اگر در یک سیستم دسته ای^۷ از درخواست های آتی دریافت شود و نیاز به مقیاس پذیری و ایجاد چندین تابع برای پاسخ به درخواستها باشد، انباشتگی تابعها برای اجرا رخ می دهد که ناشی از عدم مدیریت و تعریف سیاست های متنوع در شروع یک تابع است. در این سناریوها تاخیر شروع سرد علاوه بر تاثیر در زمان پاسخ، می تواند مشکلات دیگری از جمله ایجاد سربار اضافی و پر شدن حافظه

^۱ Function as a service

^۲ Cloud Computing

^۳ Scale-to-zero

^۴ Pay-per-use

^۵ Workflow

^۶ Cold start

^۷ Batch

اصلی را تحمیل کند که در مجموع تاخیر تجربه شده توسط کاربر را دو چندان می‌کند. معماری تابع به عنوان خدمت با وجود نقاط مثبت و جذاب برای سازمان‌ها و توسعه‌دهندگان، در صورت وقوع بیش از اندازه شروع سرد، نمی‌تواند برای سامانه‌های حساس به زمان پاسخ قابل تحمل باشد. یکی از نکات مهم برای کاهش تاخیر شروع سرد، در نظر گرفتن هزینه است [۱، ۳]. پژوهش‌های متعددی در این حوزه انجام شده است که هر یک راهکار متفاوتی را برای کاهش تاخیر شروع سرد با توجه به هزینه اتخاذ کرده‌اند. به طور کلی کاهش تعداد دفعات شروع سرد و کاهش مدت زمان شروع سرد از اصلی‌ترین رویکردهای اتخاذ شده هستند [۲]. در رویکرد اول، بعضی از مقالات از روش‌های مبتنی بر هوش مصنوعی و یادگیری ماشین برای پیش‌بینی فراخوانی تابع‌ها استفاده کرده‌اند تا پیش از دریافت درخواست تابع مورد نظر گرم و آماده شود [۴]. یکی از روش‌های معمول برای کاهش تعداد دفعات شروع سرد به‌کارگیری سیاست از پیش آماده‌سازی وابستگی‌های یک تابع و محیط اجرای آن است تا پردازش درخواست هنگام دریافت آن امکان‌پذیر باشد [۴]. یکی دیگر از رویکردهای مشترک استفاده شده، گرم نگه‌داشتن تابع به‌صورت مقطعی یا زمان‌بندی شده است که تعداد دفعات شروع سرد را کاهش می‌دهد [۶]. همچنین، می‌توان با تعریف سیاست‌های متفاوت مثل گرم نگه‌داشتن تابع‌هایی که اخیراً استفاده شده‌اند، کارایی این روش را افزایش داد [۷].

در روش‌های مبتنی بر کاهش مدت زمان شروع سرد، تغییرات عموماً در زیرساخت اجرایی سکوی تابع به عنوان خدمت انجام می‌شود. برای مثال در یکی از پژوهش‌ها، با پیاده‌سازی مکانیزم حافظه پنهان^۸، تاخیر ایجاد محیط اجرا و فراهم کردن منابع لازم کاهش یافته است [۷، ۶]. راهکار ارائه شده در این پژوهش برای تابع‌هایی که صرفاً وظایف پردازشی دارند و یا تابع‌هایی که احتیاجی به داده‌های ذخیره‌شده (در یک سیستم پایگاه داده) در زمان شروع ندارند، سودآور نخواهد بود. پژوهشی دیگر به امکان استفاده از رویکردی برای افزایش سرعت ایجاد ظرف‌های اجرایی^۹ اشاره کرده است که تاخیر شروع سرد را به میزان قابل توجهی کاهش داده است [۱۰]. پژوهشی دیگر، کاهش تاخیر شروع سرد را به مسئله‌های کوچک‌تری تقسیم کرده است و چند رویکرد با تاخیرهای متفاوت را برای آماده‌سازی تابع تعریف می‌کند. این موضوع از سربار اضافی حین ایجاد تابع‌های ثابت و مشابه جلوگیری کرده است [۱۱]. همچنین برای ذخیره‌سازی منابع پرستفاده و بازیابی پردازش‌های استفاده شده، مکانیزم‌های مدیریت حافظه اصلی و استفاده از برگرفت^{۱۰} را اتخاذ کرده است. این روش با ارائه یک سیستم عامل مخصوص معماری بدون کارساز، کاهش تاخیر شروع سرد در گردش کارهای با فراخوانی ثابت یا فراخوانی‌های دسته‌ای را به‌طور قابل‌توجهی کاهش می‌دهد. البته سختی در مهاجرت به یک زیرساخت جدید و مدیریت وابستگی‌ها از معایب این روش است. رویکردهای کاهش مدت زمان شروع سرد، محدود به محیط اجرای تابع‌ها نیست و در گروهی دیگر از پژوهش‌ها، از ابزارهای کنترل و بررسی کد تابع استفاده شده است که سعی در بهینه کردن کد و کاهش حجم وابستگی‌ها (کتابخانه‌ها) می‌کند [۵].

اغلب پژوهش‌های پیشین، مطالعات خود را روی تابع‌های تکی انجام داده‌اند و بررسی گردش کار را در تحقیقات خود در نظر نگرفته‌اند. این در حالی است که در صنعت، برای پیاده‌سازی سیستم‌های پیچیده از گردش کار استفاده می‌شود و مطالعه این حوزه می‌تواند نوآوری در کاهش شروع سرد در گردش کارها را به همراه داشته باشد. همچنین مسئله ایجاد برگرفت و پیدا کردن بهترین زمان برای انجام این عملیات، همچنان جزو مباحثی است که نیاز به پژوهش بیشتر دارد. اکثر روش‌های پیشین، اولین لحظه آمادگی تابع را مناسب‌ترین زمان برای ایجاد برگرفت از نظر پیچیدگی می‌دانند. این در حالی است که در یکی از پژوهش‌ها، ایجاد برگرفت‌های دیر هنگام‌تر نیز بررسی شده است که از انجام پردازش‌های تکراری در کد تابع نیز جلوگیری می‌کند [۱۰].

هدف این پژوهش، مطالعه عمیق‌تر مسئله شروع سرد در گردش کارها و ارائه راهکاری برای کاهش تاخیر در محیط اجرای تابع‌ها است. در پژوهش‌های پیشین، راهکارهایی با معرفی یک سیستم عامل جدید اتخاذ شده است که به‌کارگیری و استفاده آن برای سازمان‌ها و توسعه‌دهندگان را چالش برانگیز می‌کند. در این پژوهش، سادگی پیاده‌سازی و کم‌هزینه بودن استقرار راهکار پیشنهادی اهمیت دارد. همچنین تمرکز این پژوهش بر مطالعه روش‌های ایجاد برگرفت و پیدا کردن زمان مناسب انجام آن می‌باشد.

6- کلمات کلیدی فارسی: رایانش ابری، گردش کار، تابع به عنوان خدمت، رایانش بدون کارساز، شروع سرد، محیط اجرا

کلمات کلیدی انگلیسی: function-as-a-service, serverless computing, cold start, FaaS, workflow, cloud computing, runtime environment

تاریخ شروع: ۱۴۰۲/۱۰/۱

7- مدت زمان اجرای پایان نامه به ماه: ۱۸

2	4	6	8	10	12	14	16	18	20	22	24	8- مراحل اجرای پایان نامه
*	*	*	*									جمع‌آوری و بررسی منابع موجود
	*	*	*	*	*							مطالعه روش‌های ارائه شده
		*	*	*	*							ارائه راهحل پیشنهادی
				*	*	*						پیاده‌سازی راهحل پیشنهادی
					*	*	*					ارزیابی و مقایسه با سایر روش‌ها
						*	*					تهیه گزارش نهایی

9- روش پژوهش و تکنیک‌های اجرایی:

با توجه به کاربردی بودن پژوهش و امکان جمع‌آوری اطلاعات درباره چگونگی و کیفیت عملکرد سیستم، روش تجربی راهکارهای مناسبی را برای

⁸ Cache Memory

⁹ Containers

¹⁰ Snapshots

طراحی و ارائه راه حل مطلوب در اختیار می‌گذارد. هدف این پژوهش در ابتدا مطالعه و بررسی پژوهش‌های گذشته و سامانه‌های موجود و سپس، ارائه یک راه حل پیشنهادی برای بهبود تاخیر شروع سرد با توجه هزینه می‌باشد. در نهایت با انجام آزمایش‌های کنترل شده می‌توان به درک بهتری از فرضیه ارائه شده رسید و نظریه بهینه‌ای با توجه به سوالات مطرح شده در طراحی پژوهش عنوان کرد. در نهایت با استقرار یک سکوی بدون سرور متن‌باز^{۱۱} و با استفاده از مجموعه داده‌های Azure Functions Invocation Trace 2021 و Azure Functions Blob Access Trace 2020 و Azure Functions Trace 2019 با سایر روش‌ها مقایسه می‌شود [۱۲، ۱۳، ۱۴]

10- سابقه علمی و فهرست منابع:

- [۱] M. Golec, G. K. Walia, M. Kumar, F. Cuadrado, S. S. Gill, and S. Uhlig, 'Cold start latency in serverless computing: a systematic review, taxonomy, and future directions'.
- [۲] A. Ebrahimi, M. Ghobaei-Arani, and H. Saboohi, 'Cold start latency mitigation mechanisms in serverless computing: Taxonomy, review, and future directions', *J. Syst. Archit.*, vol. 151, p. 103115, Jun. 2024, doi: 10.1016/j.sysarc.2024.103115.
- [۳] P. Vahidinia, B. Farahani, and F. S. Aliee, 'Mitigating cold start problem in serverless computing: a reinforcement learning approach', *IEEE Internet Things J.*, vol. 10, no. 5, pp. 3917–3927, Mar. 2023, doi: 10.1109/JIOT.2022.3165127.
- [۴] S. Ivanenko, R. Bruno, J. Stevanovic, L. Veiga, and V. Jovanovic, 'CloudJIT: a just-in-time FaaS optimizer (work in progress)', in *Proceedings of the 20th ACM SIGPLAN International Conference on Managed Programming Languages and Runtimes*, Cascais Portugal: ACM, Oct. 2023, pp. 12–19. doi: 10.1145/3617651.3622990.
- [۵] X. Liu, J. Wen, Z. Chen, D. Li, J. Chen, Y. Liu, H. Wang, X. Jin, 'FaaSLight: General application-level cold-start latency optimization for function-as-a-service in serverless computing', *ACM Trans. Softw. Eng. Methodol.*, vol. 32, no. 5, p. 119:1-119:29, Jul. 2023, doi: 10.1145/3585007.
- [۶] R. Saha, A. Satpathy, and S. K. Addya, 'FASE: fast deployment for dependent applications in serverless environments', *J. Supercomput.*, Dec. 2023, doi: 10.1007/s11227-023-05840-w.
- [۷] B. Sethi, S. K. Addya, and S. K. Ghosh, 'LCS: Alleviating total cold start latency in serverless applications with LRU warm container approach', in *Proceedings of the 24th International Conference on Distributed Computing and Networking*, Kharagpur India: ACM, Jan. 2023, pp. 197–206. doi: 10.1145/3571306.3571404.
- [۸] B. C. Ghosh, S. K. Addya, N. B. Somy, S. B. Nath, S. Chakraborty, and S. K. Ghosh, 'Caching techniques to improve latency in serverless architectures', in *2020 International Conference on COMmunication Systems & NETworkS (COMSNETS)*, Bengaluru, India: IEEE, Jan. 2020, pp. 666–669. doi: 10.1109/COMSNETS48256.2020.9027427.
- [۹] D. Mvondo, M. Bacou, K. Nguetchouang, L. Ngale, S. Pouget, J. Kouam, R. Lachiaze, J. Hwang, T. Wood, D. Hagimont, N. De Palma, B. Batchakui, and A. Tchana, 'OFC: an opportunistic caching system for FaaS platforms', in *Proceedings of the Sixteenth European Conference on Computer Systems*, Online Event United Kingdom: ACM, Apr. 2021, pp. 228–244. doi: 10.1145/3447786.3456239.
- [۱۰] D. Fireman, P. Silva, T. E. Pereira, L. Mafra, and D. Valadares, 'Prebaking runtime environments to improve the FaaS cold start latency', *Future Gener. Comput. Syst.*, vol. 155, pp. 287–299, Jun. 2024, doi: 10.1016/j.future.2024.01.019.
- [۱۱] J. Cadden, T. Unger, Y. Awad, H. Dong, O. Krieger, and J. Appavoo, 'SEUSS: skip redundant paths to make serverless fast', in *Proceedings of the Fifteenth European Conference on Computer Systems*, Heraklion Greece: ACM, Apr. 2020, pp. 1–15. doi: 10.1145/3342195.3392698.
- [۱۲] M. Shahradd, R. Fonseca, I. Goiri, G. Chaudhry, P. Batum, J. Cooke, E. Laureano, C. Tresness, M. Russinovich, and R. Bianchini, 'Serverless in the wild: characterizing and optimizing the serverless workload at a large cloud provider', in *Proceedings of the 2020 USENIX Annual Technical Conference (USENIX ATC 20)*, Boston, Jul. 2020. [Online]. Available: <https://github.com/Azure/AzurePublicDataset/blob/master/AzureFunctionsDataset2019.md>
- [۱۳] F. Romero, G. Chaudhry, Í. Goiri, P. Gopa, P. Batum, N. J. Yadwadkar, R. Fonseca, C. Kozyrakis, and R. Bianchini, 'FaaS\$T: a transparent auto-scaling cache for serverless applications', in *Proceedings of the ACM Symposium on Cloud Computing 2021 (SoCC 21)*. ACM, Seattle, WA, 2021.
- [۱۴] Y. Zhang, Í. Goiri, G. Chaudhry, R. Fonseca, S. Elnikety, C. Delimitrou, R. Bianchini. 'Faster and cheaper serverless computing on Harvested resources', in *Proceedings of the ACM International Symposium on Operating Systems Principles (SOSP)*, October 2021.

11- وسایل و تجهیزات مورد نیاز:

¹¹ OpenWhisk Apache and OpenFaaS

12- اعتبار اجرای پایان نامه و نحوه تامین آن (ریالی و ارزی)

عنوان هزینه	ریالی	ارزی
هزینه پرسنلی وسایل و مواد مسافرت (داخل و خارج) سایر هزینه ها		
جمع کل (هزینه ها تا سقف 2/000/000 ریال قابل پرداخت می باشد)		

13- نظریه استاد راهنما:

امضاء

14- نظریه مسئول تحصیلات تکمیلی دانشکده:

امضاء

15- رئیس دانشکده :

امضاء

16- تعهدنامه دانشجو:

اینجانب دانشجوی پروژه متعهد می شوم که در مدت اجرای پروژه بطور تمام وقت انجام وظیفه نموده و بدون اطلاع معاونت پژوهشی دانشگاه از مرخصی تحصیلی استفاده ننمایم و همچنین اطلاع دارم که کلیه نتایج و حقوق حاصله از این پروژه متعلق به دانشگاه بوده و مجاز نیستم بدون موافقت دانشگاه اطلاعاتی را در رابطه با پروژه به دیگری واگذار نمایم.

نام و امضاء دانشجو

17- نظریه شورای تحصیلات تکمیلی دانشگاه :

امضاء

تاریخ

18- سایر توضیحات :